

# 在预算有限的群体感知之中激励大量未知工人： 从离线和在线的角度

## 摘要

如何在有限的预算下激励具有战略性的工人是群智感知系统中的非常基础的问题。然而，由于工人的感知能力可能由于自身传感器设备和行为的多样性而无法提前知道，因此很难正确地选择和支付这些未知质量的工人。尽管现有的工作采用组合多臂老虎机(CMAB)框架，通过探索与利用之间的权衡来解决工人的不确定性，但在工人数量庞大而预算有限的情况下，我们可能没有足够的预算在各个工人之间进行这种权衡。此外，标准的 CMAB 通常假设工人始终待在系统之中，但实际上工人可能随着时间的推移加入或离开系统，因此我们对某个工人所学到的信息在其离开之后就无法再使用。在本文中，为了解决上述具有挑战性的问题，我们首先提出了一种基于上下文感知的离线 CMAB 激励机制 (CACI)。我们创新性地在精心划分的上下文空间中利用探索与利用的权衡，而不是针对单个工人，从而在预算极其有限的情况下有效地激励大量未知质量的工人。我们还将上述基本理念扩展到在线环境之中，并提出了 CACI 机制的在线版本。在这种环境下，未知工人可能会动态地加入或离开系统。具体而言，通过上下文空间中的探索与利用的权衡，我们学会了根据任何未知工人（即使之前从未出现在系统中）的上下文信息来估计其感知能力。我们进行了严格的理论分析，以揭示 CACI 机制的遗憾上限，并分别证明其的真实性和个体理性。在合成和真实数据集上也进行了广泛的实验，以验证我们的机制的有效性。

**关键词：**群智感知；多臂老虎机；激励机制

## 1 引言

近年来，智能设备（例如，智能手机）蓬勃发展。此类设备通常配备了各类传感器，能够在广泛区域内执行感知任务。这一发展催生出了群智感知这一基本范式。具体而言，即成千上万甚至数百万的工人能够在该系统中被招募，工人利用其传感器设备在大范围区域内为各种应用（例如交通拥堵警报、空气质量监测、城市商业调查、频谱感知等）采集有价值的数

据。群智感知系统的成效在很大程度上取决于工人的质量。然而，由于成本和风险方面的顾虑，工人可能会不愿贡献自身的感知能力。例如，对于智能手机用户而言，参与收集感知数据的任务必然会导致资源消耗。此外，所收集的数据可能包含位置信息，这可能会令注重隐私的工人感到不安。因此，在给定预算的条件下激励具有策略性的工人对于群智感知系统而言是一个极为基础的问题。在本文中，我们考虑了反向拍卖，其中工人首先向任务分配者告知个人出价，然后任务分配者依据工人的感知能力和出价来决定选择哪些工人以及如何向所

选工人进行支付报酬。目前已有众多前沿的工作对激励问题展开了研究（例如），其中大多数工作假定工人的感知能力是先验知识，即是已知的。但不幸的是，这一假定并非始终适用在现实场景，因为对使用各种不同传感器设备且行为各异的工人进行预先的特征分析通常具有挑战性。当考虑到可能存在数量庞大的未知工人时，这一困难就会愈发凸显。

为了解决工人的不确定性，常用的选择是使用组合多臂老虎机（CMAB）框架，通过探索与利用依次选择未知的工人，如 [7], [8], [10], [18], [19], [28]。CMAB 框架也被应用于设计激励机制以选择和支付未知工人，如 [1]、[6] 和 [22]。而且，标准的 CMAB 框架直接解决了未知的工人个体之间探索与利用的权衡问题。但是，当预算有限而未知工人的数量巨大时，使用标准的 CMAB 框架来学习每个工人的感知能力可能会导致大量的招聘成本。例如，当给定的预算不足以选择和支付每个工人至少一次，那么基于标准 CMAB 框架的激励机制将是不切实际的启动。

另一个具有挑战性的问题是工人的动态到达和离开。工人可能不能一直持续工作，随着时间的推移，他们可能会陆续加入或离开系统 [14]、[26] 和 [29]。在这种场景下且工人的感知能力未知时，标准的 CMAB 框架不再适用，因为它学习的是每个个体的感知能力。特别地，对于任何未知工人，即使系统已经很好地学习了他们的感知能力，但在工人离开后关于工人的感知能力的知识也将不能使用了。虽然现在也有许多变体老虎机框架被应用于会变化的工人之上 [2], [13]，但是他们是基于标准的多臂老虎机，并且将他们的想法应用到组合问题上是非常重要的，因此很少有工作努力将框架扩展到 CMAB 框架。

在本文中，我们首先提出了一种基于上下文感知和 CMAB 框架的离线激励机（Context-Aware CMAB-based Incentive, CACI），以在有限的预算下激励大群的固定的未知工人。普遍认为，具有相似上下文的工人通常具有相似的感知能力 [16], [21]，因此我们创新地利用 CMAB 框架学习上下文和感知能力之间的相关性，而不只是单个工人个体的感知能力。特别地，离线 CACI 机制主要包括两个阶段，即探索阶段和利用阶段。在探索阶段，我们将上下文空间划分为有限粒度的子空间（即“超立方体”），迭代地探索超立方体以估计每个超立方体中具有相似上下文的工人的感知能力的上置信界（Upper Confidence Bounds, UCBs）。在利用阶段，我们以贪婪的方式根据估计对工人进行利用。此外，我们还设计了一个支付所选工人的策略，保证了总预算约束以及激励机制的真实性和个人理性。通过离线的 CACI 机制来探索和利用有限的上下文空间分区，我们可以有效地激励一群固定且大量的未知工人来最大化预期的累积感知收入，即使总预算相当有限。

我们基于上述的基本思想设计了 CACI 机制的在线版本，即当大量的未知工人随着时间动态地加入或离开系统。与离线机制相对应，在线的 CACI 机制在精心划分的上下文空间中进行探索-利用的权衡，但由于工人的动态性，将是以一种完全不同的方式进行。在每次探索和利用的迭代中，我们更新可用工人的上置信界，以在线的方式做出对工人的选择和支付的决策。在线 CACI 机制在学习上下文空间和感知能力之间的相关性方面做出了创新，即使给定一个以前从未在系统中出现过的工人，也可以根据上下文准确地估计该工人的感知能力，并做出适当的选择和支付决策。

## 2 相关工作

激励机制的设计在群智感知 [25] 中起着重要的作用。目前已有 [4], [9], [17], [27] 从不同的角度研究激励问题。然而, 大多数工作都假设工人的感知能力是已知的。

为了解决群智感知系统中工人的不确定性, 一个流行的方法是使用 CMAB 框架。例如, 在 [10]、[18] 和 [28] 中, 在有限的总预算下, 具有未知感知能力的工人被依次选择来执行给定的感知任务。[19] 采用工人报告的数据的经验熵来测量传感收入。[7] 和 [8] 调查了多任务分配问题。在上述工作中, CMAB 框架中的手臂 (例如, [10]、[18]、[19] 和 [28] 中的工人或 [7] 和 [8] 中的工人-任务组合) 被单独利用和探索。因此, 这些传统的基于 CMAB 的算法效率较低, 特别是在手臂数量较大而总预算有限的情况下。此外, 这些工作虽然考虑到了工人的不确定性, 但他们没有考虑到激励问题。

CMAB 框架还可以用于设计工人感知能力未知情境下的群智感知系统的激励机制。例如, [1]、[6]、[22] 提出了对预算有限的未知工人进行招聘的激励机制。不幸的是, 所有现有的工作都采用了 CMAB 框架, 使得工人个体之间能够进行探索-利用的权衡。但当未知工人的数量巨大而预算有限时, 他们的性能将会下降。

上下文信息对于群智感知系统是有用的, 并且已广泛应用于设计工人选择算法之中 [20], [24]。例如, 在 [12] 中, 感知任务被分配给与他们的环境相似的工人, 他们认为如果一个工人的上下文更类似于感知任务, 那么该工人更合适。[23] 也研究了感知任务与工人之间的匹配关系, 他们考虑了任务的要求和工人的偏好。[11] 提出了新的数据结构来提高任务-工人匹配的性能。然而, 这些工作并没有考虑到工人的不确定性。[15] 使用了一个以离线方式训练的基于上下文的数据质量分类器来识别合格的工人。[16] 采用基于上下文的 MAB 方法来理解工人的感知能力如何同时依赖于工人和任务的上下文信息。虽然这些工作采用了机器学习技术, 并根据上下文信息来选择未知的工人, 但它们没有考虑工人的策略。[21] 设计了一种基于上下文感知和 MAB 框架的激励机制, 但是没有考虑预算的限制。

## 3 本文方法

### 3.1 符号定义

给定一个有预算  $B$  的感知任务和一个固定的  $N$  个工人  $\mathcal{N} = \{1, 2, \dots, N\}$ , 每个工人  $i \in \mathcal{N}$  首先不公开地将其出价  $b_i \in [b_{\min}, b_{\max}]$  发送给任务分配者, 然后任务分配者决定选择哪些工人以及如何支付所选工人的报酬。时间跨度设置为  $\mathcal{T} = \{1, 2, \dots, T\}$ 。在每个时间间隔  $t \in \mathcal{T}$  中, 选定的工人将收集并上传数据样本。我们假设  $r_i^{[t]} \in \{0, 1\}$  表示一个独立同分布的伯努利随机变量, 并且代表若工人  $i$  在时间间隔  $t$  收集的数据是否是合格的。这也可以解释为我们通过选择工人  $i$  在时间间隔  $t$  中进行感知任务所获得的奖励。对于每个工人  $i \in \mathcal{N}$ , 我们假设  $\mu_i = \mathbb{E}[r_i^{[t]}]$  for  $t = 1, 2, \dots$ , 这实际上代表了工人  $i$  的感知能力 (或质量), 因此我们可以通过招募工人  $i$  获得奖励。我们假设任务分配者的  $\mu_i$  是未知的, 并设  $\mathbf{m} = (\mu_1, \mu_2, \dots, \mu_N)$  为感知能力向量。我们也让  $\mathbf{b} = (b_1, b_2, \dots, b_N)$  表示出价的向量。

虽然工人的感知能力是未知的, 但我们假设对于每个工人  $i \in \mathcal{N}$  的上下文  $s_i \in \mathcal{S}$  都可以被观察到, 其中  $\mathcal{S} \triangleq [0, 1]^M$  是所谓的“上下文空间”, 而  $M$  是上下文空间的维数。上下文空间的维度包括工人对某些所需技能的熟练程度、工人的个人背景和传感器设备的性能参数等,

这些与工人的感知能力密切相关。因此，我们可以根据工人的上下文来获得工人的感知能力。工人  $i$  对上下文  $s_i$  的感知能力被定义为  $\mu(s_i) = \mathbb{E}[r(s_i)]$ 。换句话说，对于在时间间隔  $t$  中被选择的工人，我们有  $\mu_i = \mathbb{E}[r_i^{[t]}] = \mathbb{E}[r(s_i)]$ ，且有  $\mu_{max} = \max_{s \in \mathcal{S}} \mu(s)$  和  $\mu_{min} = \min_{s \in \mathcal{S}} \mu(s)$ ，并且  $\mathbf{s} = (s_1, s_2, \dots, s_N)$  表示工人集合  $\mathcal{N}$  的上下文向量。

### 3.2 离线 CACI 算法概述

我们的离线预算有限的激励  $K$  工人 (K-WIN) 的问题可以如下 (1)-(8) 所示。具体来说，我们设计了机制  $F_{off}$ ，使得目标函数 (1) (即通过我们的机制获得的期望累积感知奖励  $R(F_{off})$ ) 在满足约束 (2)-(8) 的情况下最大化：

$$\max R(F_{off}) = \mathbb{E} \left[ \sum_{t=1}^T \sum_{i \in \mathcal{N}} x_i^{[t]} r_i^{[t]} \right] \quad (1)$$

$$\text{s.t. } \sum_{i \in \mathcal{N}} x_i^{[t]} \geq K \cdot z^{[t]}, \quad \forall t \in \mathcal{T} \quad (2)$$

$$\sum_{t=1}^T \sum_{i \in \mathcal{N}} p_i^{[t]} \leq B \quad (3)$$

$$x_i^{[t]} \leq z^{[t]}, \quad \forall i \in \mathcal{N}, t \in \mathcal{T} \quad (4)$$

$$z^{[t]} \geq z^{[t+1]}, \quad \forall t \in \mathcal{T} \quad (5)$$

$$\phi_i(x_i^{[t]}, p_i^{[t]}; c_i, \mathbf{b}_{-i}) \geq \phi_i(x_i^{[t]}, p_i^{[t]}; b_i, \mathbf{b}_{-i}),$$

$$\forall i \in \mathcal{N}, \forall t \in \mathcal{T}, \forall b_i \in [b_{\min}, b_{\max}],$$

$$\forall \mathbf{b}_{-i} \in [b_{\min}, b_{\max}]^{N-1} \quad (6)$$

$$\phi_i(x_i^{[t]}, p_i^{[t]}) \geq 0, \quad \forall i \in \mathcal{N}, t \in \mathcal{T} \quad (7)$$

$$x_i^{[t]}, z^{[t]} \in \{0, 1\}, \quad \forall i \in \mathcal{N}, t \in \mathcal{T} \quad (8)$$

我们提供了对这些约束条件的解释，具体说明如下：

- 鲁棒性约束 (2)：在每个时间间隔  $t$  中，为了提高鲁棒性，我们至少选择了  $K$  个工人。
- 预算限制 (3)：经过  $T$  时间间隔的支付总价不超过预算  $B$ 。
- 可行性限制 (4)-(5)：如 (4) 所示，只有在执行感知任务时，才会选择工人。此外，我们引入了约束 (5)，在不牺牲一般性的情况下，限制其维数，以保证问题的可解性；假设我们跨越时间跨度  $\mathcal{T}$  连续选择工人。
- 真实性 (6)：每个工人  $i$  都必须如实传达自己的个人出价，因为以真正的成本作为出价总是能最大化自身的效用，无论其他工人的投出价。
- 个人理性 (7)：机制必须实现个人理性，即参与拍卖的每个工人都有非负效用。

我们的机制是基于这样一个事实：具有相似情境的工人通常具有相似的感知能力。因此，我们首先将上下文空间  $\mathcal{S}$  划分为一组  $d^M$  不相交的超立方体，其中  $d$  表示划分的粒度。超立方体具有相同的大小为  $1/d^M$ 。我们用  $\mathcal{Q}$  表示超立方体的集合，让  $Q(i)$  表示其中的第  $i$  个超

立方体，这样就有  $s_i \in Q(i)$ 。如果工人  $i$  在时间间隔  $t$  中被选择，那么就可以说是  $Q(i)$  在时间间隔  $t$  中被选中。通过微调的  $d$ ，同一超立方体中的工人具有相似的感知能力，我们估计任何工人  $i$  的感知能力为  $Q(i)$  的感知能力。我们的机制是通过利用超立方体之间的探索-利用权衡来学习它们的“感知能力”，并根据它们的上下文估计未知的工人。

在实现算法时，我们运用到了两个中间参数， $\lambda^{[t]}(Q)$  和  $\bar{r}^{[t]}(Q)$ ，分别表示选择  $Q$  的总次数和选择  $Q$  到时间间隔  $t$  获得的平均累积奖励，具体的计算公式如下所示：

$$\lambda^{[t]}(Q) = \lambda^{[t-1]}(Q) + \sum_{i \in \mathcal{N}^{[t]}} \mathbb{I}(s_i \in Q) \quad (9)$$

$$\bar{r}^{[t]}(Q) = \frac{\bar{r}^{[t-1]}(Q) \cdot \lambda^{[t-1]}(Q) + \sum_{i \in \mathcal{N}^{[t]}} \mathbb{I}(s_i \in Q) \cdot r_i^{[t]}}{\lambda^{[t]}(Q)} \quad (10)$$

在利用阶段，我们将计算  $Q$  的感知能力的上置信界（UCB）为

$$u_i = \bar{r}^{[t-1]}(Q(i)) + \sqrt{\frac{\ln B}{\lambda^{[t-1]}(Q(i))}} \quad (11)$$

然后，我们为每个工人  $i$  定义一个权重为  $\rho_i = u_i/b_i$ ，并根据  $\rho_i$  按递减顺序排序，选择出前  $K$  个工人，记为  $\tilde{\mathcal{N}}$ 。最后对任何工人  $i \in \tilde{\mathcal{N}}$  的支付可以通过如下的公式进行计算：

$$\tilde{p}_i = \min \left\{ \frac{u_i}{\rho_{K+1}}, b_{\max} \right\} \quad (12)$$

算法结束于预算  $B$  耗尽之时。

### 3.3 在线 CACI 算法概述

我们现在考虑一个在线场景，工人可以以在线的方式加入或离开群智感知系统，在线 K-WIN 问题表述如下：

$$\max R(F_o) = \mathbb{E} \left[ \sum_{t=1}^T \sum_{i \in \mathcal{N}^{[t]}} x_i^{[t]} r_i^{[t]} \right] \quad (13)$$

$$\text{s.t.} \quad \sum_{i \in \mathcal{N}^{[t]}} x_i^{[t]} \geq K \cdot z^{[t]}, \quad \forall t \in \mathcal{T} \quad (14)$$

$$\sum_{t=1}^T \sum_{i \in \mathcal{N}^{[t]}} p_i^{[t]} \leq B \quad (15)$$

$$x_i^{[t]} \leq z^{[t]}, \quad \forall i \in \mathcal{N}, t \in \mathcal{T} \quad (16)$$

$$z^{[t]} \geq z^{[t+1]}, \quad \forall t \in \mathcal{T} \quad (17)$$

$$\phi_i(x_i^{[t]}, p_i^{[t]}; c_i, \mathbf{b}_{-i}) \geq \phi_i(x_i^{[t]}, p_i^{[t]}; b_i, \mathbf{b}_{-i}),$$

$$\forall i \in \mathcal{N}^{[t]}, \forall t \in \mathcal{T}, \forall b_i \in [b_{\min}, b_{\max}],$$

$$\forall \mathbf{b}_{-i} \in [b_{\min}, b_{\max}]^{N-1} \quad (18)$$

$$\phi_i(x_i^{[t]}, p_i^{[t]}) \geq 0, \quad \forall i \in \mathcal{N}^{[t]}, t \in \mathcal{T} \quad (19)$$

$$x_i^{[t]}, z^{[t]} \in \{0, 1\}, \quad \forall i \in \mathcal{N}^{[t]}, t \in \mathcal{T} \quad (20)$$

如上式所示，在线 CACI 算法的目标函数和约束实际上与离线 CACI 算法的目标函数和约束非常相似。我们通过考虑在线工人的动态到达和离开来重新定义它们。具体来说，在每个时间间隔  $t$  中，我们从给定的可用工人集合  $\mathcal{N}^{[t]}$  中选择至少  $K$  个工人，以确保感知的鲁棒性，并保证在  $\mathcal{N}^{[t]}$  中每个工人的真实性和个体理性。

接下来，我们将具体介绍如何设计一个有效的机制来激励在线工人。因为工人的动态性，导致在每个时间间隔中的可用工人可能会有所不同，因此学习个体工人的感知能力是不可行的。幸运的是，由于不确定的工人的上下文空间是固定的，我们可以学习上下文和感知能力之间的映射，从而选择并支付高质量工人。在线算法的细节和离线算法也非常相似，但是在计算上置信界（UCB）时，在线算法需要重新设置为如下的公式：

$$u_i^{[t]} = \bar{r}^{[t-1]}(Q(i)) + \sqrt{\frac{(K+1) \ln t}{\lambda^{[t-1]}(Q(i))}} \quad (21)$$

## 4 复现细节

### 4.1 与已有开源代码对比

该工作未开源任何相关代码，论文复现完全根据论文之中的伪代码和相关论述进行完成代码。

### 4.2 实验环境搭建

实验环境基于 pycharm 进行 python 代码的编写，使用的 python 版本为 3.12，具体使用的一些库的版本号如下所示：

- pandas==2.2.2
- numpy==2.1.0
- matplotlib==3.9.2
- scipy==1.14.1

### 4.3 改进点

创新地使用了真实的无人机数据集，并对其进行了数据处理之后才进行了实验，数据集的具体介绍将在后续章节给出。并且我们将该工作与近几年的算法进行了对比，突出了其的优越性能。

## 5 实验结果分析

本部分将介绍实验的对比算法和具体设置，并对实验所得结果进行描述并分析。



## 5.1 数据集、实验设置和对比算法介绍

在本小节中，我们首先介绍一下我们在实验中使用的数据集 [3]，这是一个真实世界的无人机数据集，来自 Evans 关于索耶工厂大坝拆除的研究。在这项研究中，图像采集和目标检测任务在美国新罕布什尔州的多佛进行，使用配备了原始 RGB 相机和偏光过滤器的 DJI 幻影 3 专业无人机。飞行参数包括纬度、经度、航向 (deg) 和曲线大小 (ft)，都记录在 CSV 文件中。受无人机平台的约束，CSV 文件包含 99 个路径点。这些路径点可以被视为单个工人，因此工人的最大数量  $N$  被设置为 99。曲线大小 (ft) 表示每个路径点所覆盖的检测/图像区域，显著影响无人机的任务性能，因此被指定为每个工人的平均效用。而路径点的经纬度则作为工人的位置。




图 1. 美国新罕布什尔州多佛的索耶米尔大坝研究的无人机飞行路径的实际路径

至于其他设置，设置预算的范围为  $[1000, 10000]$ ，默认为 5000，而选择工人的数量  $K$  的范围为  $[5, 15]$ ，默认为 5。工人的真实花费 (cost) 从  $[0.1, 0.6]$  中随机选取，而投标价格将从  $[\text{cost}, 1]$  中随机选取。

最后，我们介绍对比算法：

- Baseline：在每个工人的感知能力作为先验知识已知的情况下得出的近乎最优解，并且该机制确保了真实性和个体理性。基准线机制主要用于计算遗憾值。
- Random：一种简单的策略，即随机且均匀地选择  $K$  名工人。
- AUCB [6]：一种同样使用 UCB 的预算受限学习策略，每轮选择  $K$  名工人。
- UWR [5]：一种基于扩展 UCB 的拉臂策略，用于解决上下文多臂老虎机问题，并设计相应的未知工人在线招募算法。

## 5.2 实验结果

在该章节，离线的 CACI 机制和在线的 CACI 机制将在真实数据集上进行评估，分别对比了在不同数量的工人数  $N$  和不同大小的预算  $B$  对机制的影响。

### 5.2.1 离线 CACI 机制

我们首先研究了不同机制在不同工人总数下的表现，并将工人总数从 25 改变到 99，如图 2 所示。从图中我们可以得知，基线算法是最优的，而我们的离线算法是除了基线算法外最优的机制，且性能远超越别的机制，无论是在累计奖励方面还是在遗憾值方面。

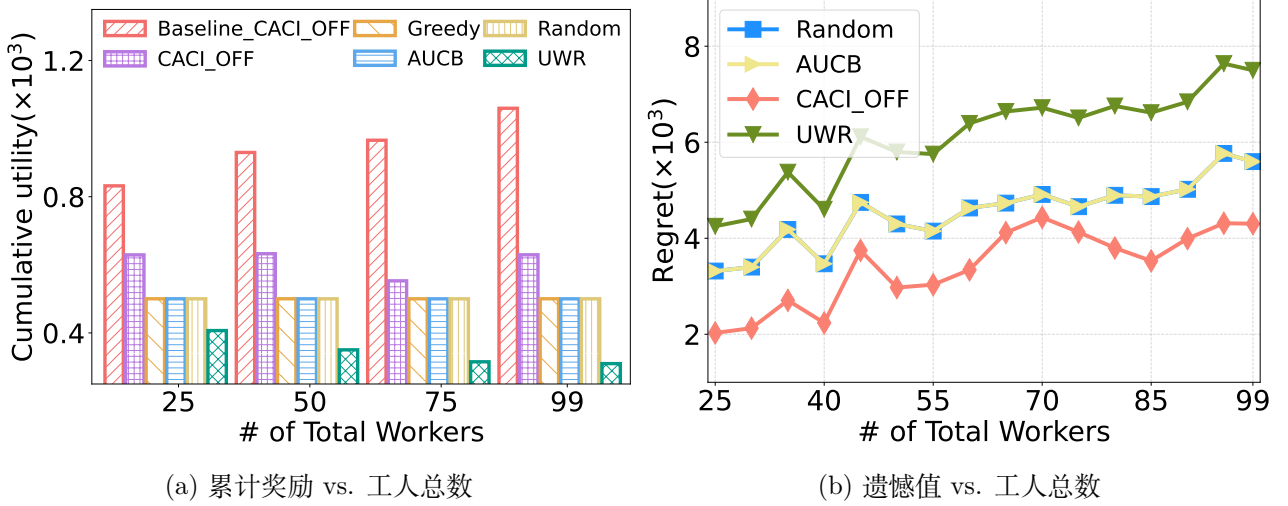


图 2. 测试不同数量的工人总数对离线机制的影响

接着，我们评估了不同机制在不同预算下的表现，将预算从 1000 变化到了 10000，具体的结果如图 3 所示。展示的结果和在不同工人总数的结果类似，我们的机制在累计奖励方面和遗憾值方面总是除了基线算法外最优的机制，展现出了我们离线机制的优越性能。

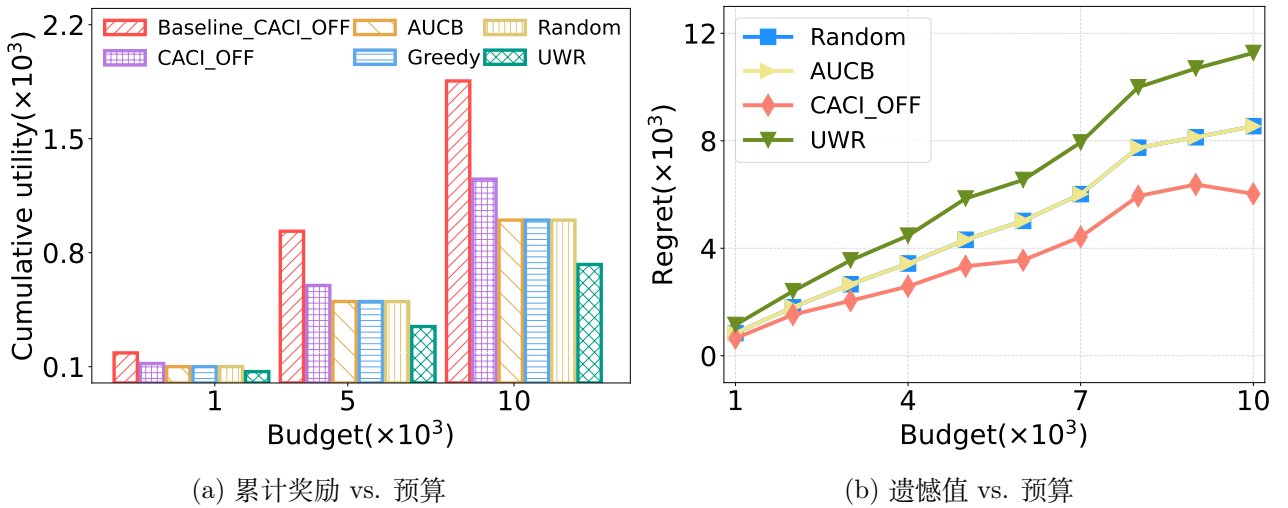



图 3. 测试不同大小的预算对离线机制的影响


### 5.2.2 在线 CACI 机制

在该章节，我们研究在线 CACI 机制的表现并评估其的性能。具体的评估方法和离线 CACI 机制的一直，也是从不同数量的工人数  $N$  和不同大小的预算  $B$  这两方面对比累计奖励和遗憾值。具体的结果如图 4 和图 5 所示，展示出了我们在线 CACI 的优越性能。



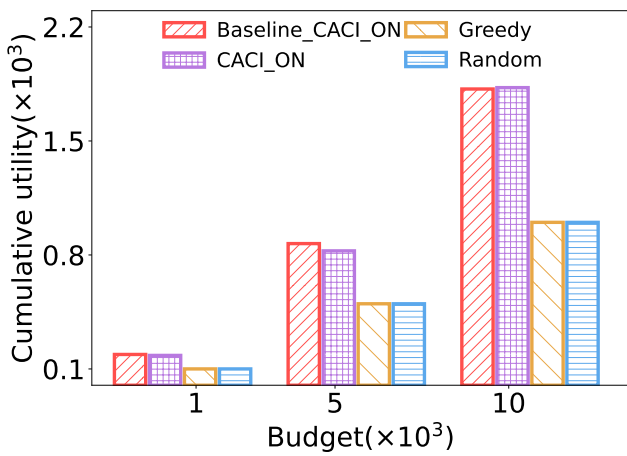


(a) 累计奖励 vs. 工人总数




(b) 遗憾值 vs. 工人总数

图 4. 测试不同数量的工人总数对在线机制的影响



(a) 累计奖励 vs. 预算



(b) 遗憾值 vs. 预算

图 5. 测试不同大小的预算对在线机制的影响

## 6 总结与展望

本工作研究了如何在基于上下文的 CMAB 框架中, 且预算有限的情况下激励大量未知的工人, 并提出了离线的 CACI 机制, 在精心划分的上下文空间中进行探索和利用的权衡, 以代替只在工人个体之中进行探索和利用。同时本工作基于上述的想法提出了在线的 CACI 机制以解决工人的动态性, 即工人会随着时间的推移, 动态地加入或者离开系统。虽然工人具有不确定性, 但是工人的上下文和感知能力之间的相关性可通过我们的机制进行学习, 故在选择工人的时候可以根据上下文来估计可用工人的感知能力以选择高质量的工人。离线 CACI 机制和在线 CACI 机制都保证了真实性和个人理性, 并在真实数据集上进行了广泛的实验, 以验证所提出机制的有效性。

但是该工作的假设过强, 假设了工人的上下文即感知能力是遵循一定分布的, 这个在现实场景之中难以实现, 因为实现场景之中, 工人的感知能力是随机且离散的。所以需要进一步设计一个普适性更强的, 即无论工人感知能力的分布如何, 都可以快速选出感知能力高的工人。除此之外, 该工作也没有考虑到工人的个人隐私需求。因为该工作的机制设计之中, 在

选择工人时需要工人的上下文信息作为输入，而上下文信息是工人的个人隐私，泄露将对工人带来损失。故需要进一步加入隐私保护的方法，如差分隐私技术。以上两点都是我未来可研究的方向，目前已在投入研究。

## 参考文献

- [1] Arpita Biswas, Shweta Jain, Debmalaya Mandal, and Y Narahari. A truthful budget feasible multi-armed bandit mechanism for crowdsourcing time critical tasks. In *AAMAS*, pages 1101–1109, 2015.
- [2] Zahy Bnaya, Rami Puzis, Roni Stern, and Ariel Felner. Volatile multi-armed bandits for guaranteed targeted social crawling. In *Workshops at the Twenty-Seventh AAAI Conference on Artificial Intelligence*, 2013.
- [3] Evans and Alexandra. Sawyer mill dam removal project sediment area drone flight paths. 5 2021.
- [4] Zhenni Feng, Yanmin Zhu, Qian Zhang, Lionel M Ni, and Athanasios V Vasilakos. Trac: Truthful auction for location-aware collaborative sensing in mobile crowdsourcing. In *IEEE INFOCOM 2014-IEEE Conference on Computer Communications*, pages 1231–1239. IEEE, 2014.
- [5] Guoju Gao, He Huang, Mingjun Xiao, Jie Wu, Yu-E Sun, and Yang Du. Budgeted unknown worker recruitment for heterogeneous crowdsensing using cmab. *IEEE Transactions on Mobile Computing*, 21(11):3895–3911, 2022.
- [6] Guoju Gao, He Huang, Mingjun Xiao, Jie Wu, Yu-E Sun, and Sheng Zhang. Auction-based combinatorial multi-armed bandit mechanisms with strategic arms. In *IEEE INFOCOM 2021-IEEE Conference on Computer Communications*, pages 1–10. IEEE, 2021.
- [7] Guoju Gao, Jie Wu, Mingjun Xiao, and Guoliang Chen. Combinatorial multi-armed bandit based unknown worker recruitment in heterogeneous crowdsensing. In *IEEE INFOCOM 2020-IEEE Conference on Computer Communications*, pages 179–188. IEEE, 2020.
- [8] Guoju Gao, Jie Wu, Zhaoyang Yan, Mingjun Xiao, and Guoliang Chen. Unknown worker recruitment with budget and covering constraints for mobile crowdsensing. In *2019 IEEE 25th International Conference on Parallel and Distributed Systems (ICPADS)*, pages 539–547. IEEE, 2019.
- [9] Guoju Gao, Mingjun Xiao, Jie Wu, Liusheng Huang, and Chang Hu. Truthful incentive mechanism for nondeterministic crowdsensing with vehicles. *IEEE Transactions on Mobile Computing*, 17(12):2982–2997, 2018.

- [10] Kai Han, Chi Zhang, and Jun Luo. Taming the uncertainty: Budget limited robust crowdsensing through online learning. *Ieee/acm transactions on networking*, 24(3):1462–1475, 2015.
- [11] Lei Han, Zhiwen Yu, Zhiyong Yu, Liang Wang, Houchun Yin, and Bin Guo. Online organizing large-scale heterogeneous tasks and multi-skilled participants in mobile crowdsensing. *IEEE Transactions on Mobile Computing*, 22(5):2892–2909, 2021.
- [12] Alireza Hassani, Pari Delir Haghighi, and Prem Prakash Jayaraman. Context-aware recruitment scheme for opportunistic mobile crowdsensing. In *2015 IEEE 21st International Conference on Parallel and Distributed Systems (ICPADS)*, pages 266–273. IEEE, 2015.
- [13] Robert Kleinberg, Alexandru Niculescu-Mizil, and Yogeshwer Sharma. Regret bounds for sleeping experts and bandits. *Machine learning*, 80(2):245–272, 2010.
- [14] Youqi Li, Fan Li, Song Yang, Pan Zhou, Liehuang Zhu, and Yu Wang. Three-stage stackelberg long-term incentive mechanism and monetization for mobile crowdsensing: An online learning approach. *IEEE Transactions on Network Science and Engineering*, 8(2):1385–1398, 2021.
- [15] Shengzhong Liu, Zhenzhe Zheng, Fan Wu, Shaojie Tang, and Guihai Chen. Context-aware data quality estimation in mobile crowdsensing. In *IEEE INFOCOM 2017-IEEE Conference on Computer Communications*, pages 1–9. IEEE, 2017.
- [16] Sabrina Klos née Müller, Cem Tekin, Mihaela van der Schaar, and Anja Klein. Context-aware hierarchical online learning for performance maximization in mobile crowdsourcing. *IEEE/ACM Transactions on Networking*, 26(3):1334–1347, 2018.
- [17] Dan Peng, Fan Wu, and Guihai Chen. Data quality guided incentive mechanism design for crowdsensing. *IEEE transactions on mobile computing*, 17(2):307–319, 2017.
- [18] Anshuka Rangi and Massimo Franceschetti. Multi-armed bandit algorithms for crowdsourcing systems with online estimation of workers’ ability. In *AAMAS*, pages 1345–1352, 2018.
- [19] Yiwen Song and Haiming Jin. Minimizing entropy for crowdsourcing with combinatorial multi-armed bandit. In *IEEE INFOCOM 2021-IEEE Conference on Computer Communications*, pages 1–10. IEEE, 2021.
- [20] Hamed Vahdat-Nejad, Elham Asani, Zohreh Mahmoodian, and Mohammad Hossein Mohseni. Context-aware computing for mobile crowd sensing: A survey. *Future Generation Computer Systems*, 99:321–332, 2019.
- [21] Yue Wu, Fan Li, Liran Ma, Yadong Xie, Ting Li, and Yu Wang. A context-aware multiarmed bandit incentive mechanism for mobile crowd sensing systems. *IEEE Internet of Things Journal*, 6(5):7648–7658, 2019.

- [22] Mingjun Xiao, Jing Wang, Hui Zhao, and Guoju Gao. Unknown worker recruitment in mobile crowdsensing using cmab and auction. In *2020 IEEE 40th International Conference on Distributed Computing Systems (ICDCS)*, pages 1145–1155. IEEE, 2020.
- [23] Fatih Yucel, Murat Yuksel, and Eyuphan Bulut. Qos-based budget constrained stable task assignment in mobile crowdsensing. *IEEE Transactions on Mobile Computing*, 20(11):3194–3210, 2020.
- [24] Özgür Yürür, Chi Harold Liu, Zhengguo Sheng, Victor CM Leung, Wilfrido Moreno, and Kin K Leung. Context-awareness for mobile sensing: A survey and future directions. *IEEE Communications Surveys & Tutorials*, 18(1):68–93, 2014.
- [25] Xinglin Zhang, Zheng Yang, Wei Sun, Yunhao Liu, Shaohua Tang, Kai Xing, and Xufei Mao. Incentives for mobile crowd sensing: A survey. *IEEE Communications Surveys & Tutorials*, 18(1):54–67, 2015.
- [26] Dong Zhao, Xiang-Yang Li, and Huadong Ma. Budget-feasible online incentive mechanisms for crowdsourcing tasks truthfully. *IEEE/ACM Transactions on Networking*, 24(2):647–661, 2014.
- [27] Dong Zhao, Xiang-Yang Li, and Huadong Ma. How to crowdsource tasks truthfully without sacrificing utility: Online incentive mechanisms with budget constraint. In *IEEE INFOCOM 2014-IEEE Conference on Computer Communications*, pages 1213–1221. IEEE, 2014.
- [28] Hui Zhao, Mingjun Xiao, Jie Wu, Yun Xu, He Huang, and Sheng Zhang. Differentially private unknown worker recruitment for mobile crowdsensing using multi-armed bandits. *IEEE Transactions on Mobile Computing*, 20(9):2779–2794, 2020.
- [29] Zhenzhe Zheng, Shuo Yang, Jiapeng Xie, Fan Wu, Xiaofeng Gao, and Guihai Chen. On designing strategy-proof budget feasible online mechanisms for mobile crowdsensing with time-discounting values. *IEEE Transactions on Mobile Computing*, 21(6):2088–2102, 2020.